King County 房價預測

多元線性回歸 (Multiple Linear Regression) 分析報告

依循 CRISP-DM 流程

項目	內容
課程 / 作業	物聯網數據分析與應用 / HW2
姓名	王鼎昌
學號	7115064172
資料來源	kc_house_data.csv（King County, WA 房屋交易資料，2014–2015）
分析工具	Python 3：pandas、statsmodels、scikit-learn、matplotlib、seaborn
完成日期	2026 年 10 月 15 日

摘要

本報告以 King County 21,613 筆房屋交易資料，建立多元線性回歸模型預測房價，並依 CRISP-DM 六階段完成商業理解、資料理解、資料準備、建模、評估與部署。因房價嚴重右偏，目標變數取自然對數 log(price)，並以 80/20 切分訓練與測試集。

關鍵結果	數值
最終模型變數數	17 個（逐步迴歸自 18 個候選變數中剔除 has_basement）
訓練集 / 測試集 R^2	0.802 / 0.810
5-Fold 交叉驗證 R^2	平均 0.804（標準差 0.004）
測試集 MAE / RMSE（美元）	$98,522 / $168,193
測試集平均絕對百分比誤差 (MAPE)	約 18.1%
95% 預測區間實際覆蓋率	95.2%（測試集）
單純線性回歸對照（僅 log_sqft_living）	測試集 R^2 = 0.468

1. 商業理解 (Business Understanding)

1.1 問題情境與目標

房地產仲介與買家需要依據房屋條件（面積、品質、地段等）快速估算合理成交價。本研究以多元線性回歸預測房價 (price)，同時找出影響房價的關鍵因素，並以預測區間量化預測的不確定性。

1.2 成功標準與達成情形

成功標準	實際結果	是否達成
測試集 $R^2 \geq 0.80$（log 價格尺度）	0.810	達成
係數可解釋且符號合理	grade、面積、waterfront 等為正向；bedrooms 為負（偏相關，見 4.4）	達成
提供預測值與 95% 信賴 / 預測區間	圖 8、圖 9；預測區間覆蓋率 95.2%	達成

2. 資料理解 (Data Understanding)

2.1 資料概況

項目	結果
資料筆數 / 欄位數	21,613 筆 / 21 欄
缺失值	0
完全重複列	0
重複 id（同一房屋多次交易）	177 筆（視為不同交易，保留）
目標變數 price	平均 $540,088；中位數 $450,000；最小 $75,000；最大 $7,700,000
price 偏態 (skewness)	4.02（取 log 後降為 0.43）

表：主要欄位說明

欄位	說明
price	成交價格（目標變數，美元）
bedrooms / bathrooms / floors	臥室數 / 衛浴數 / 樓層數
sqft_living / sqft_lot	室內居住面積 / 土地面積（平方英尺）
sqft_above / sqft_basement	地上樓層面積 / 地下室面積
waterfront / view	是否臨水岸 (0/1) / 景觀評分 (0–4)
condition / grade	屋況 (1–5) / 建築與裝修品質等級 (1–13)
yr_built / yr_renovated	建造年份 / 整修年份（0 表示未整修）
zipcode / lat / long	郵遞區號 / 緯度 / 經度
sqft_living15 / sqft_lot15	鄰近 15 戶平均居住面積 / 土地面積

2.2 價格分布

價格呈明顯右偏（少數豪宅拉高平均），取 log 後分布接近常態，有利於線性回歸對常態性與等變異數的假設。

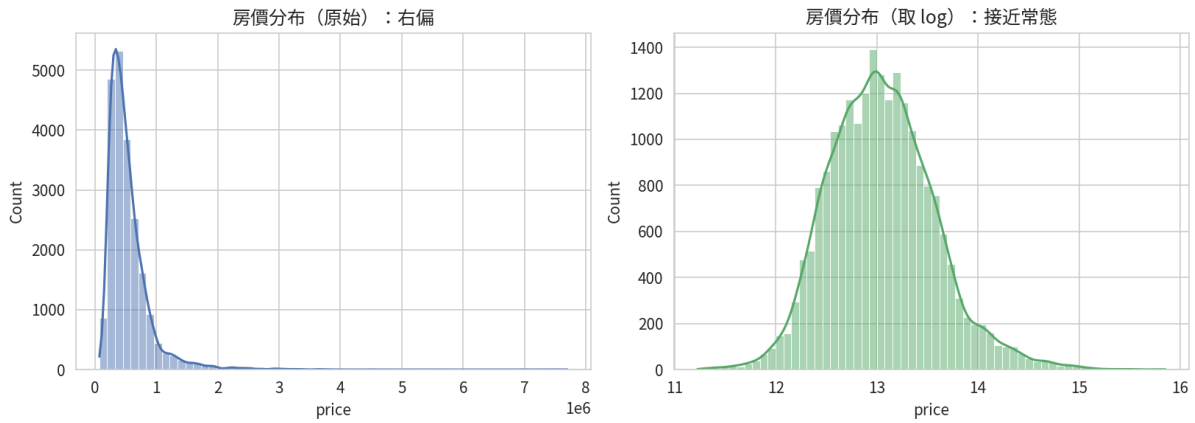


圖 1　房價分布：原始（左）與取 log 後（右）

2.3 相關性分析

與 price 相關係數最高的變數依序為 sqft_living (0.702)、grade (0.667)、sqft_above (0.606)、sqft_living15 (0.585)、bathrooms (0.525) 與 view (0.397)；long、condition、yr_built 與房價的線性相關極低。

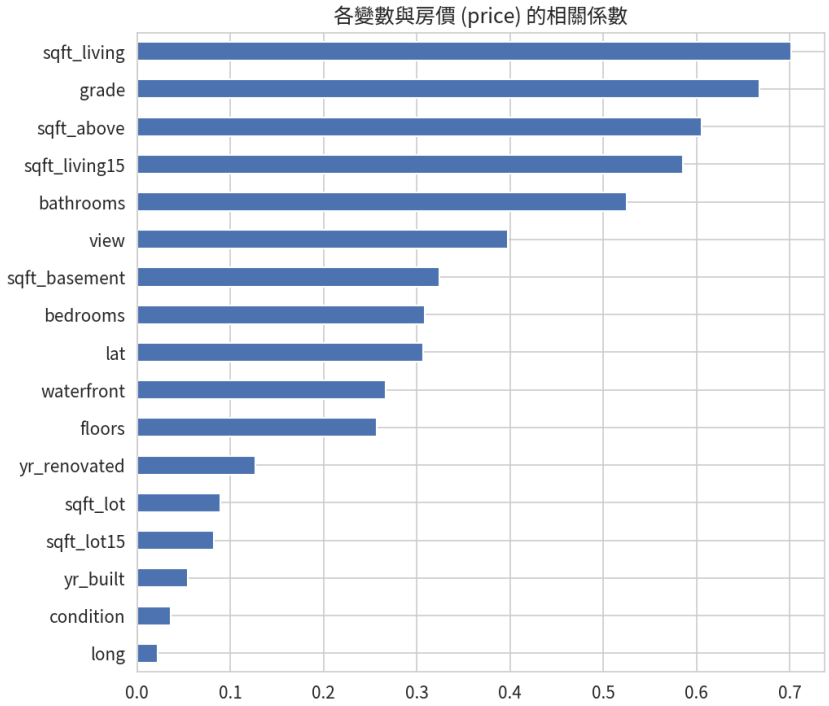


圖 2　各變數與房價 (price) 的相關係數

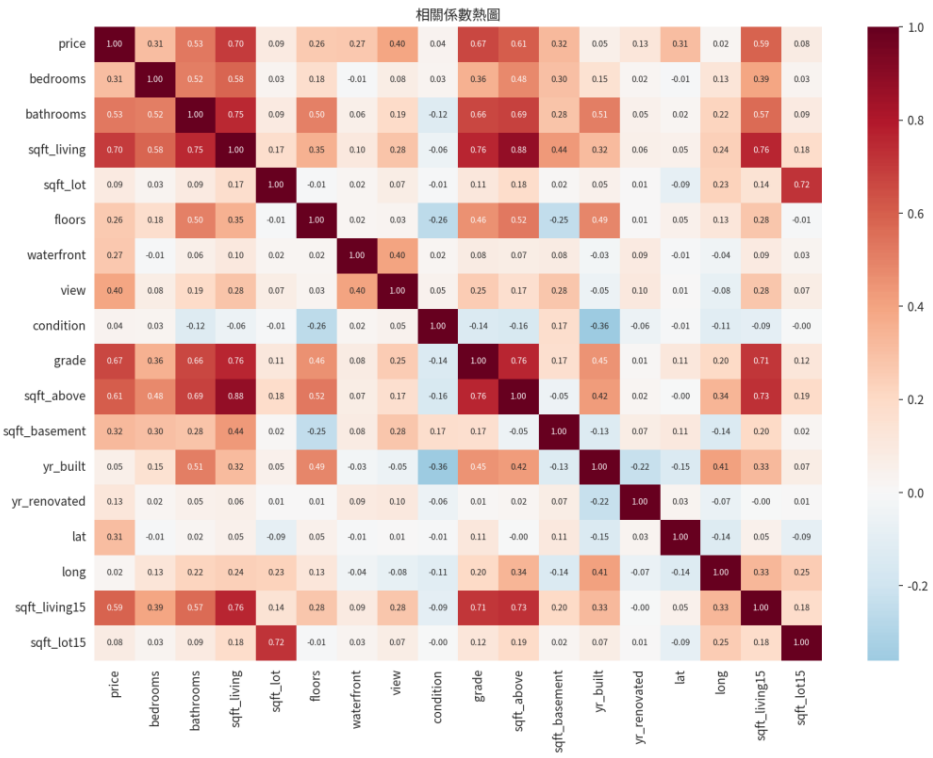


圖 3　相關係數熱圖

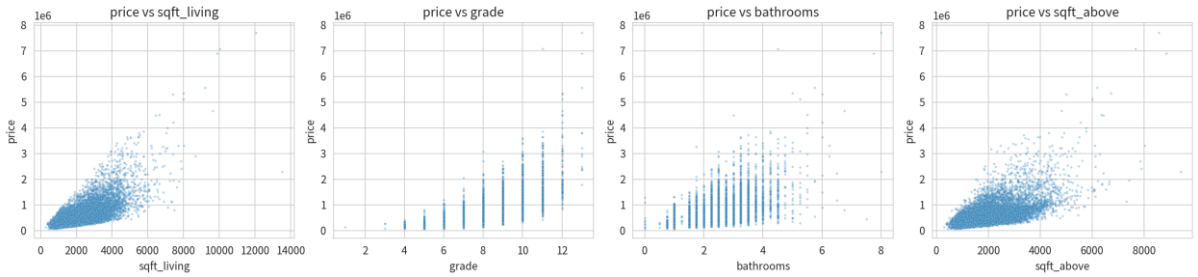


圖 4　重點變數與房價散佈圖

2.4 初步觀察

- sqft_living、grade、bathrooms 與房價呈明顯正向關係，是預測的核心變數。
- sqft_above + sqft_basement = sqft_living，三者完全共線，建模前須處理。
- bedrooms 出現 33 間的異常值，疑為輸入錯誤。
- 價格嚴重右偏，應取 log 轉換。

3. 資料準備 (Data Preparation)

3.1 異常值處理

移除 bedrooms ≥ 10 共 5 筆（輸入錯誤），並以 log(price) 的 3×IQR 準則移除 6 筆極端價格，資料由 21,613 筆減為 21,602 筆。採較寬鬆的 3×IQR 是為了保留合理的高價房，避免模型低估豪宅區間。

3.2 特徵工程

處理	說明
目標變數取 log	log(price) 使分布接近常態，係數可解讀為百分比變動
面積取 log	sqft_living、sqft_lot、sqft_living15、sqft_lot15 取 log 降低偏態
處理完全共線	捨棄 sqft_above、sqft_basement，以 has_basement (0/1) 取代
屋齡與整修	house_age = 交易年 − yr_built；renovated = (yr_renovated > 0)
交易年份	sold_2015 (0/1) 控制 2014 與 2015 年的市場差異
地段	zipcode 有 70 類，改用 lat、long 與「距西雅圖市中心距離 dist_downtown_km」（Haversine 公式）
類別變數	waterfront、renovated、has_basement、sold_2015 為二元變數，無須額外編碼

3.3 多重共線性檢查 (VIF)

特徵工程後計算 VIF，最大值為 log_sqft_lot 的 7.00，全部低於常用門檻 10，因此未再移除任何變

數。

變數	VIF	變數	VIF	變數	VIF
log_sqft_lot	7.00	house_age	2.56	has_basement	1.60
log_sqft_lot15	6.71	long	2.46	view	1.38
log_sqft_living	5.87	floors	2.20	condition	1.24
dist_downtown_km	4.03	lat	1.94	waterfront	1.21
bathrooms	3.31	bedrooms	1.86	renovated	1.15
grade	3.17	log_sqft_living15	2.84	sold_2015	1.01

3.4 資料切分

以 random_state = 42 隨機切分 80% 訓練集（17,281 筆）與 20% 測試集（4,321 筆）。

4. 建模 (Modeling)

4.1 模型設定

多元線性回歸模型：log(price) = β0 + β1X1 + β2X2 + … + βpXp + ε。以 statsmodels OLS 取得完整統計推論（係數、p 值、信賴區間、F 檢定），並以 scikit-learn LinearRegression 驗證，兩者截距皆為 54.3928，結果一致。

4.2 特徵選擇

方法	結果
VIF 檢查	全部 VIF < 10，無須剔除
向後逐步迴歸 (p > 0.05 逐一剔除)	僅剔除 has_basement (p = 0.083)，保留 17 個變數，皆達顯著
LassoCV (5-fold，標準化後)	最佳 α = 0.000366，沒有任何係數被壓縮為 0，與逐步迴歸結論一致

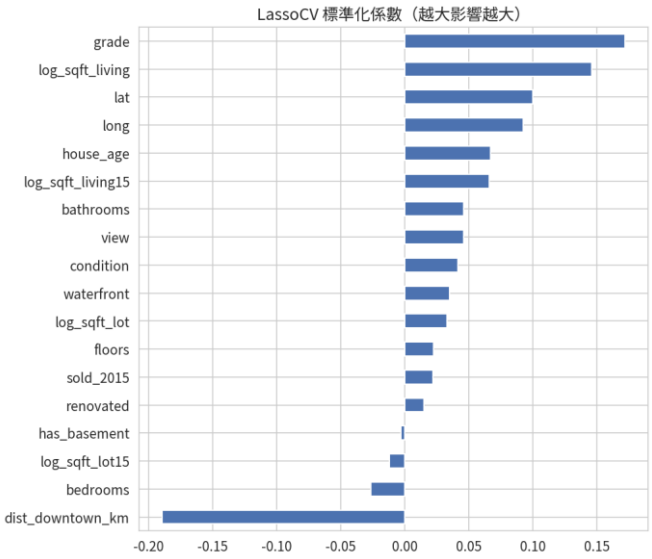


圖 5　LassoCV 標準化係數

4.3 最終模型摘要（訓練集）

統計量	數值	統計量	數值
R^2	0.802	觀測數	17,281
Adj. R^2	0.802	解釋變數數	17
F 統計量	4,123	Prob (F)	< 0.001
AIC	−1,327	BIC	−1,187
Durbin-Watson	2.008	殘差偏態 (Skew)	−0.036

4.4 迴歸係數與解讀

因變數為 log(price)，連續變數增加 1 單位，房價約變動 (e^β − 1) × 100%；log_sqft_* 為彈性係數，面積增加 1%，房價約增加 β%。

變數	係數 β	95% CI 下限	95% CI 上限	p 值	價格變動 %
lat	0.7175	0.6827	0.7522	< 0.001	104.92
long	0.6628	0.6243	0.7014	< 0.001	94.03
waterfront	0.4198	0.3745	0.4651	< 0.001	52.16
log_sqft_living	0.3403	0.3215	0.3592	< 0.001	40.54
log_sqft_living15	0.2032	0.1854	0.2210	< 0.001	22.54

變數	係數 β	95% CI 下限	95% CI 上限	p 值	價格變動 %
grade	0.1469	0.1417	0.1522	< 0.001	15.83
renovated	0.0759	0.0572	0.0947	< 0.001	7.89
condition	0.0647	0.0587	0.0706	< 0.001	6.68
bathrooms	0.0600	0.0517	0.0682	< 0.001	6.18
view	0.0595	0.0542	0.0648	< 0.001	6.13
sold_2015	0.0477	0.0402	0.0551	< 0.001	4.88
floors	0.0459	0.0372	0.0546	< 0.001	4.70
log_sqft_lot	0.0418	0.0317	0.0519	< 0.001	4.27
house_age	0.0023	0.0021	0.0025	< 0.001	0.23
dist_downtown_km	−0.0178	−0.0184	−0.0171	< 0.001	−1.76
log_sqft_lot15	−0.0204	−0.0314	−0.0095	< 0.001	−2.02
bedrooms	−0.0304	−0.0357	−0.0252	< 0.001	−3.00

解讀重點：

- **居住面積與品質**：log_sqft_living 彈性為 0.34（面積 +1%，房價約 +0.34%）；grade 每提高一級，房價約 +15.8%。
- **臨水岸 (waterfront)**：同條件下房價約高 52%，為影響最大的二元變數。
- **地理位置**：lat、long 單位為「度」（1 度約 100 公里），係數很大屬正常，且須與 dist_downtown_km 一併解讀為地理位置效應，不宜單獨解釋。
- **bedrooms 為負**：在控制居住面積後，臥室越多代表每間房越小，房價反而略低（偏相關，並非臥室讓房子變便宜）。
- **house_age 為正**：控制品質後，老屋（多位於市中心附近成熟地段）略有溢價。

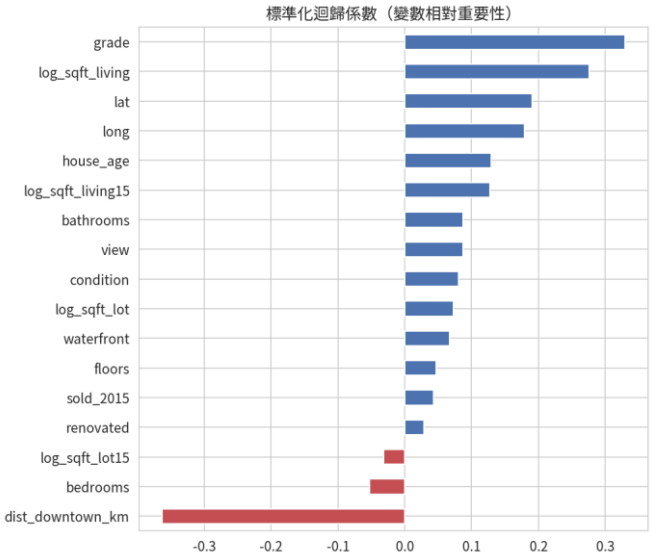


圖 6　標準化迴歸係數（變數相對重要性）

5. 評估 (Evaluation)

5.1 模型比較

R^2、Adj. R^2、RMSE (log) 為 log 價格尺度；RMSE ($)、MAE ($)、MAPE 為還原成美元後的結果。

模型	R^2	Adj. R^2	RMSE (log)	RMSE ($)	MAE ($)	MAPE (%)
A 全變數 OLS（訓練）	0.8024	0.8022	0.2326	158,483	96,218	18.25
A 全變數 OLS（測試）	0.8100	0.8092	0.2317	168,073	98,495	18.15
B 最終 OLS（訓練）	0.8024	0.8022	0.2326	158,623	96,231	18.25
B 最終 OLS（測試）	0.8100	0.8092	0.2318	168,193	98,522	18.15
Lasso（測試）	0.8100	0.8092	0.2318	168,250	98,568	18.15
Ridge（測試）	0.8100	0.8092	0.2317	168,113	98,506	18.15

各模型表現幾乎相同，且訓練集與測試集差距很小，顯示沒有過擬合；樣本數大，正則化（Lasso、Ridge）幫助有限。最終採用較精簡、可解釋性高的模型 B。

交叉驗證：5-Fold R^2 分別為 0.8105、0.8020、0.8045、0.8008、0.8003，平均 0.8036，標準差 0.0037，模型穩定。

單純 vs 多元：僅用 log_sqft_living 的單純線性回歸測試集 R^2 為 0.468，多元線性回歸提升至 0.810（+0.342），說明品質、地段等變數對預測貢獻很大。

5.2 迴歸假設檢驗

假設	方法	結果	判讀
線性	殘差 vs 預測值圖	殘差圍繞 0 隨機散佈，無明顯曲線	大致符合
獨立性	Durbin-Watson	2.008	接近 2，無自相關
等變異數	Breusch-Pagan	LM = 964.6，p ≈ 3×10^-194	存在輕微異質變異
常態性	Shapiro-Wilk（抽樣 5,000）；Q-Q 圖	W = 0.9923，p < 0.001；偏態 −0.04；超額峰度 1.13	中段貼合，尾部略厚
影響點	Cook's distance	最大值 0.0081（遠小於 1）	無極端影響點

樣本數很大時，Breusch-Pagan 與 Shapiro-Wilk 幾乎必然達顯著，因此應搭配圖形判讀。殘差偏態接近 0，Q-Q 圖僅在兩端略偏離常態線；Cook's D 雖有 1,072 筆（6.2%）超過 4/n 參考線，但最大值僅 0.0081，不構成極端影響。係數的標準誤可能因異質變異而略有偏誤，若需更嚴謹的推論，可改用穩健標準誤 (HC3)。

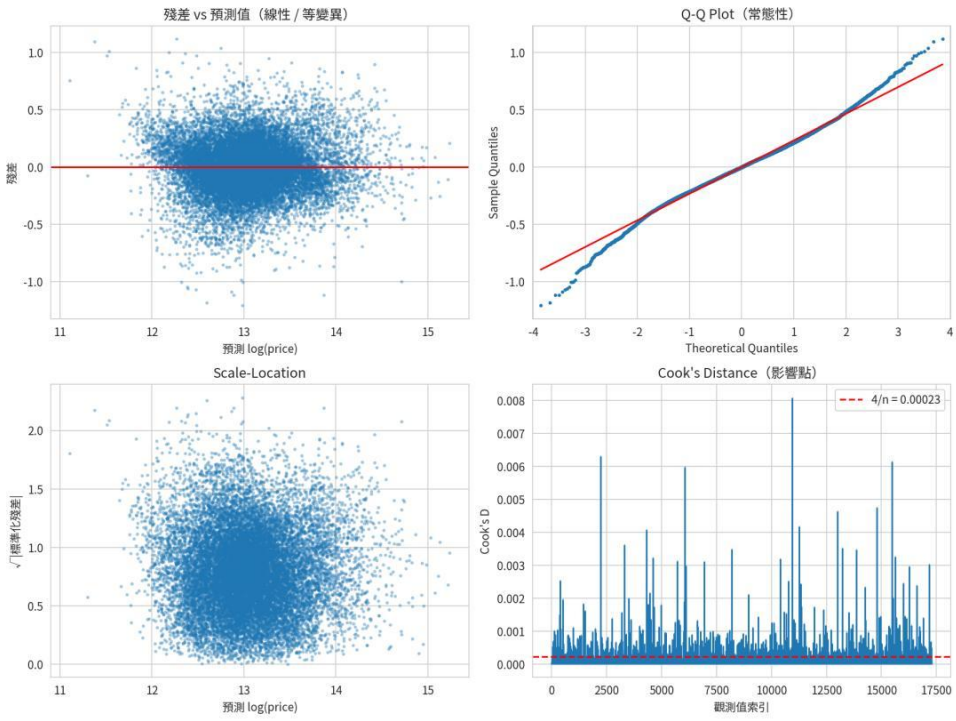


圖 7　殘差診斷圖：殘差 vs 預測值、Q-Q Plot、Scale-Location、Cook's Distance

5.3 預測圖：信賴區間與預測區間

圖 8 左圖將測試集依預測值由低至高排序，疊上預測值、95% 信賴區間 (CI) 與 95% 預測區間 (PI)；右圖為實際房價對預測房價。信賴區間描述「平均房價」估計的不確定性，因此很窄；預測區間描述「單一房屋」價格的不確定性，因此較寬。測試集實際價格落在 95% 預測區間內的比例為 95.2%，與理論值吻合。

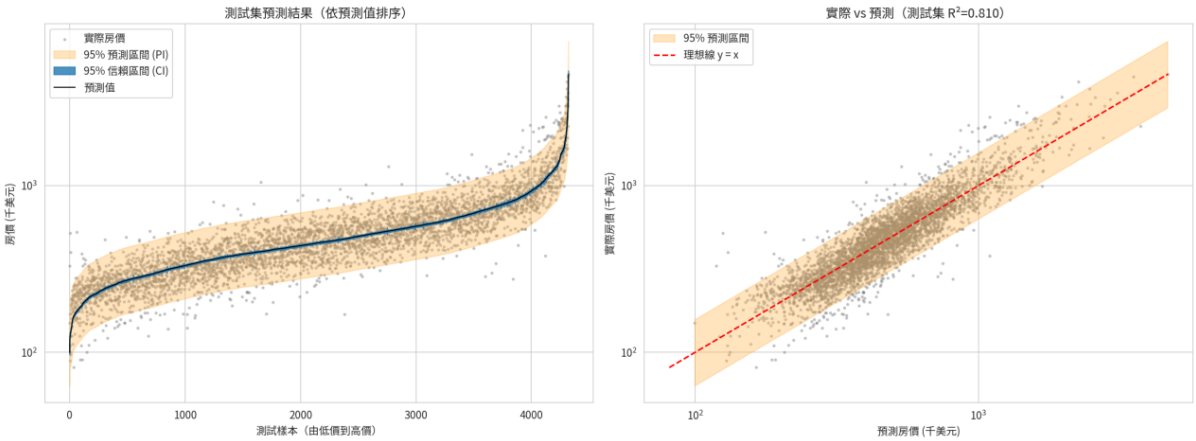


圖 8　測試集預測結果與 95% 信賴區間 / 預測區間

圖 9 固定其餘變數於平均值，僅改變居住面積，呈現面積對房價的預測曲線及其區間。區間在 log 尺度對稱，還原成美元後呈上寬下窄，符合高價房波動較大的特性。

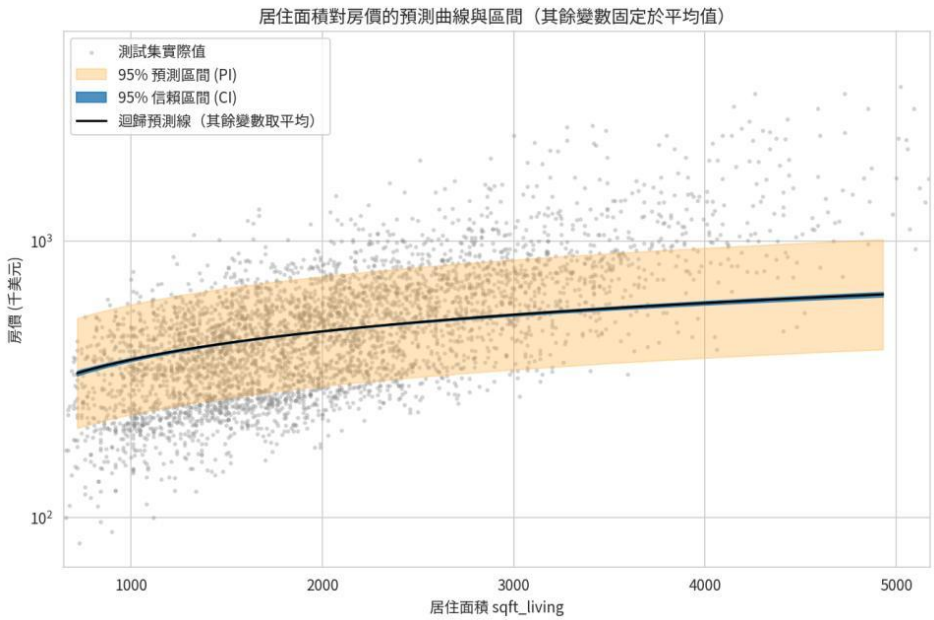


圖 9　居住面積對房價的預測曲線（其餘變數固定於平均值）

> 註：預測值由 exp(預測 log 價格) 還原，嚴格而言是價格的中位數估計，會略低於平均值；區間因 exp 為單調轉換而仍然有效。

5.4 小結

- 模型解釋約 81% 的 log 房價變異，測試集 MAPE 約 18%，達成 $R^2 \geq 0.80$ 的目標。
- 訓練集、測試集與交叉驗證表現一致，無明顯過擬合。
- 限制：存在輕微異質變異；地段僅以經緯度與距市中心距離近似，非線性的空間效應未完全捕捉；高價房預測誤差較大。
- 改進方向：加入郵遞區號或空間特徵（如 k-NN 鄰近房價）、交互作用項、非線性模型（梯度提升）作為比較，或使用穩健標準誤。

6. 部署 (Deployment)

6.1 模型封裝與使用

最終模型以 joblib 儲存為 `house_price_model.joblib`，並提供 `predict_price()` 函式：輸入原始房屋欄位，內部自動套用相同特徵工程，回傳預測房價、95% 信賴區間與 95% 預測區間（美元）。

使用範例（資料集第一筆房屋，id = 7129300520，實際價格 $221,900）

輸出項目	結果
預測房價	$314,435
95% 信賴區間	$311,459 ~ $317,440
95% 預測區間	$199,237 ~ $496,240

此範例屬訓練資料，實際價格落在預測區間內，但預測值高於實際成交價，說明單一房屋的誤差可能不小，應以區間而非單一數值作為決策參考。

6.2 部署建議與限制

- 可包成 Flask / FastAPI 或 Streamlit 應用，讓仲介輸入房屋條件即時估價。
- 資料為 2014–2015 年，應定期以新資料重新訓練，避免市場漂移。
- 模型不適用於資料範圍之外的情況（極端豪宅、非 King County 地區）。
- 上線後應持續監控預測誤差（MAPE、區間覆蓋率），超出門檻時觸發重訓。

7. 結論

本研究依 CRISP-DM 流程完成房價多元線性回歸分析。經 log 轉換、特徵工程與逐步迴歸特徵選擇，最終模型測試集 R^2 達 0.810，5-Fold 交叉驗證 R^2 為 0.804，且預測區間實際覆蓋率為 95.2%，三項成功標準皆達成。影響房價最顯著的因素為地理位置、是否臨水岸、居住面積與建築品質 (grade)。模型的主要限制在於輕微異質變異與空間效應的線性近似，後續可透過空間特徵與非線性模型進一步改善。

8. AI 對話紀錄

使用者（第 1 輪）

我要做一份作業，目標是能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。

Claude

這份作業可以照 CRISP-DM 的六個階段來規劃，以下是各階段在多元線性回歸中該做的事。

各階段重點

1. 商業理解 (Business Understanding)

- 說明問題情境與預測目標，例如「預測房價」或「預測汽車油耗」。
- 定義成功標準，例如 R^2、RMSE 達到多少，或找出哪些變數影響最大。

2. 資料理解 (Data Understanding)

- 資料來源、筆數、欄位說明、型態。
- 描述性統計、缺失值、分布圖、相關係數矩陣與熱圖、散佈圖矩陣。
- 初步觀察哪些變數與目標變數相關。

3. 資料準備 (Data Preparation)

- 處理缺失值與異常值（IQR 或 Z-score）。
- 類別變數做 One-Hot Encoding，必要時對偏態變數取 log。
- 檢查多重共線性（VIF）。
- 切分訓練集與測試集（例如 80/20），必要時標準化。

4. 建模 (Modeling)

- 用 statsmodels OLS 取得完整統計報告（係數、p-value、F 檢定、Adj. R^2）。
- 用 scikit-learn LinearRegression 做預測。
- 可進行變數選擇（逐步回歸、移除 p 值不顯著或 VIF 過高的變數），並與 Ridge/Lasso 比較。

5. 評估 (Evaluation)

- 訓練集與測試集的 R^2、Adj. R^2、RMSE、MAE。

- 做 K-fold 交叉驗證。
- 檢驗回歸假設：線性（殘差 vs 預測值圖）、常態性（Q-Q plot、Shapiro-Wilk）、等變異數（Breusch-Pagan）、獨立性（Durbin-Watson）。
- 檢查離群點與影響點（Cook's distance）。
- 解讀係數的實際意義，並回到商業目標檢討是否達標。

6. 部署 (Deployment)

- 作業中通常是總結結論、模型限制與改進建議。
- 可選擇附上預測函式或簡單的使用範例。

建議的交付形式

Jupyter Notebook（.ipynb）或 Python 程式碼，搭配報告，每個 CRISP-DM 階段一個章節，圖表加上文字解讀。

為了幫你做出可以直接交的內容，我想先確認一件事：**老師有指定資料集嗎？**如果有，請告訴我名稱或上傳檔案；如果沒有，我可以幫你挑一個適合的（例如 California Housing、Auto MPG 或 Student Performance），並直接產出完整的 Notebook，附程式碼與每階段的分析說明。

使用者（第 2 輪）

[上傳檔案：kc_house_data.csv]

作業內容：

1. 資料來源：上述檔案
2. 分析任務：使用線性回歸 (Linear Regression) 模型進行預測。可嘗試單純線性回歸、多元線性回歸或 Auto Regression。必須執行 特徵選擇 (Feature Selection) 與 模型評估 (Model Evaluation)。結果部分需包含請提供預測圖 (加上信賴區間 或 預測區間)。
3. CRISP-DM 流程說明：Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation、Deployment
4. 整理程式，整理成主程式

Claude

[Claude 讀取資料集（21,613 筆、無缺失值）、安裝套件、撰寫並執行 main.py、檢查輸出圖表，產出

main.py、results 資料夾與 results_all.zip。]

我已把整個 CRISP-DM 流程寫成單一主程式 main.py 並跑完，測試集 R^2 為 0.810，達到我自訂的 0.80 目標。results_all.zip 內含程式與全部輸出（9 張圖、report.txt、係數與模型比較 CSV、模型檔），report.txt 有完整的終端輸出。

執行方式：

```
pip install pandas numpy matplotlib seaborn scipy scikit-learn statsmodels joblib
python main.py --data kc_house_data.csv --out results
```

各階段做了什麼

CRISP-DM 階段	主要內容
1. 商業理解	目標是預測房價，並訂出成功標準：測試集 $R^2 \geq 0.80$、係數可解讀、提供預測區間
2. 資料理解	21,613 筆、無缺失值；價格偏態 4.02，取 log 後降到 0.43；另有相關係數熱圖與散佈圖
3. 資料準備	剔除 11 筆異常值（bedrooms ≥ 10 與價格極端值）；建立特徵並計算 VIF；80/20 切分訓練與測試集
4. 建模與特徵選擇	比較向後逐步迴歸（p 值）、LassoCV 與 VIF；另以全變數 OLS、sklearn LinearRegression 與 Ridge 對照
5. 評估	指標、5-fold 交叉驗證、迴歸假設檢驗、Cook's distance、係數解讀，以及帶信賴區間與預測區間的預測圖
6. 部署	儲存模型，並提供 predict_price() 函式，輸入房屋資料即回傳預測價與兩種區間

主要結果

- **預測表現：**訓練集 R^2 為 0.802，測試集為 0.810，5-fold 交叉驗證平均 0.804，沒有明顯過擬合。還原成美元後，平均絕對誤差約 $98,500，平均誤差百分比約 18%。
- **單純 vs 多元回歸：**只用 log_sqft_living 的單純線性回歸測試集 R^2 為 0.468，多元回歸提升到 0.810。
- **預測區間：**測試集實際值落在 95% 預測區間的比例是 95.2%，與理論值吻合。

- **特徵選擇**：VIF 檢查沒有變數超過 10；逐步迴歸只剔除 has_basement（p = 0.083），Lasso 沒有壓縮任何變數。全變數、逐步迴歸、Lasso、Ridge 的表現幾乎相同，因為樣本數大，正則化幫助有限。

預測圖（作業要求的信賴區間與預測區間）

- **圖 08**：左圖是測試集依預測值排序，並疊上 95% 信賴區間與預測區間；右圖是實際值對預測值。
- **圖 09**：居住面積對房價的預測曲線，其餘變數固定在平均值，同樣畫出兩種區間。

幾個設計決定

- **目標變數取 log(price)**：價格嚴重右偏，取 log 後殘差較接近常態。預測值與區間再用 exp 還原成美元；由於 exp 是單調轉換，區間仍然有效。
- **處理共線性**：sqft_above + sqft_basement = sqft_living，三者完全共線，所以我改用 has_basement 取代前兩者。
- **地段處理**：zipcode 有 70 類，改用 lat、long 與自己計算的「距西雅圖市中心距離」。

報告裡建議講清楚的地方

- Breusch-Pagan 檢定拒絕等變異數（p ≈ 3e-194），而 Shapiro-Wilk 也拒絕常態。我在報告中說明這是樣本數大時檢定過度敏感，並搭配 Q-Q 圖判讀；異質變異則列入模型限制。
- bedrooms 的係數為負，是因為已控制居住面積，臥室越多代表每間越小。lat 與 long 的係數很大是因為單位是「度」，應與 dist_downtown_km 合併視為地理位置效應。
- 5-fold 交叉驗證與測試集 R^2 分別是 0.804 與 0.810，差異是正常的隨機波動。

中文圖表字型會依序嘗試微軟正黑體、PingFang、Noto Sans CJK，若你的電腦都沒有，字會變成方框，可把程式開頭字型清單改成你系統有的中文字型。

[附上檔案：main.py、report.txt、08_prediction_test_set_with_intervals.png、09_prediction_curve_sqft_living.png、results_all.zip]

使用者（第 3 輪）

Report 幫我弄成 word 檔（格式不要跑掉）

Claude

[Claude 建立 Word 報告、通過格式驗證，轉成 PDF 逐頁檢查版面，並調整表格避免跨頁被切斷。同時把 main.py 中 Q-Q 圖的描述改為「中段貼合、兩端尾部略偏離」，並重新執行。]

Word 報告已完成：房價預測_多元線性回歸報告.docx，共 13 頁，A4。檔案已通過 Word 格式驗證，我也轉成 PDF 逐頁檢查過版面。

報告內容

- **封面與摘要：**標題、課程 / 姓名 / 學號填寫欄（先留空，請自己補）、關鍵結果表。
- **1 到 6 章：**依 CRISP-DM 順序，每章都有表格、圖表與文字解讀。
- **第 7 章與附錄：**結論，以及程式與輸出檔案清單。
- **圖表：**9 張圖都已嵌入，每張有編號與圖說，其中包含帶信賴區間與預測區間的預測圖（圖 8、圖 9）。
- **表格：**17 個變數的完整係數表（含 95% 信賴區間與 p 值）、模型比較表、假設檢驗表等。

讓格式不跑掉的做法

- 表格使用固定欄寬，並設成不跨頁切斷，避免只剩一列被丟到下一頁。
- 中文字型指定為「微軟正黑體」，頁首與頁尾的頁碼是 Word 的自動欄位。
- 標題使用 Word 內建的標題樣式，所以你可以在 Word 裡用「參考資料 → 目錄」自行插入目錄。

兩點提醒

1. 我預覽時電腦沒有微軟正黑體，用替代字型轉檔，所以實際在 Word 開啟時，字型與換行位置可能略有差異，但不會影響整體結構。
2. 我順手把 main.py 裡 Q-Q 圖的描述改成「中段貼合、兩端尾部略偏離」，因為看圖後發現尾部確實偏離常態線，先前寫的「大致良好」不夠精確。報告也採用這個說法，report.txt 已同步更新。

另外，報告裡有一處沒有出現在先前的終端輸出：我建議在假設檢驗段提到可改用穩健標準誤 (HC3)，因為 Breusch-Pagan 檢定顯示有異質變異。這是延伸建議，我沒有實際跑，如果老師要求再補。

9. NotebookLM 研究摘要

參考資料：https://github.com/nadinezab/kc-house-prices-prediction

以下為本報告與上述參考資料在做法上的差異整理。

9.1 解法比較

模型與指標總覽

項目	GitHub Model A	GitHub Model B	本研究（最終模型）
模型	多元線性回歸	多元線性回歸	多元線性回歸（OLS）
特徵數量	17 個（郵遞區號分級）	87 個（Zipcode One-Hot）	17 個
目標變數	原始價格（美元）	原始價格（美元）	log(price)
Adj. R^2	0.701	0.832	0.802（訓練集） 0.809（測試集）
R^2	未提供	未提供	測試集 0.810
RMSE（美元）	$132,444 （10-Fold CV 平均）	$99,654 （10-Fold CV 平均）	$168,193 （20% 測試集）
交叉驗證	10-Fold	10-Fold	5-Fold（平均 R^2 0.804）

逐項處理方式對照

面向	GitHub 專案	本研究
異常值（如 bedrooms = 33）	README 未詳述剔除規則；EDA 中分析了房間數與價格的關係	移除 bedrooms ≥ 10 共 5 筆；以 log(price) 的 3×IQR 準則移除 6 筆極端價格
價格是否取 log	否，直接以美元建模與評估	是。價格偏態 4.02，取 log 後降至 0.43
地理位置	Model A：70 個 Zipcode 依房價中位數分級；Model B：Zipcode One-Hot；另用 Folium、Geopandas、Geopy 製作地圖	以 lat、long 與 Haversine 距離 dist_downtown_km 取代 Zipcode
共線性與面積變數	EDA 檢視各面積變數與價格的關係，保留主要面積變數	sqft_above + sqft_basement = sqft_living 完全共線，改用 log_sqft_living 與 has_basement；VIF 最大值 7.00（< 10）
特徵選擇	以 EDA 相關性與地區分級，比較 17 特徵與 87 特徵兩組，並用 10-Fold CV 選模型	VIF 過濾、向後逐步迴歸（剔除 has_basement）、LassoCV 交叉比對

9.2 與本研究的對照

相同的做法

- 核心方法皆為多元線性回歸。
- 皆使用 King County 2014–2015 年房屋交易資料。
- 皆以 K-Fold 交叉驗證評估泛化能力（對方 10-Fold，本研究 5-Fold）。
- 皆認為地理位置與建築品質等級 (grade) 是影響房價的重要因素。

不同的做法

- **目標變數**：本研究對價格與面積取 log；對方維持原始金額。
- **地理特徵**：對方用 Zipcode 類別編碼（最多 87 個變數）；本研究用 3 個連續空間變數。

- **統計檢驗**：本研究做了 VIF、Durbin-Watson、Breusch-Pagan、Shapiro-Wilk、Cook's Distance 與預測區間；對方的 README 偏重商業導向的探索性分析與行銷建議（針對 PropertiesInc）。

R^2 比較與可能原因

本研究最終模型測試集 R^2 為 0.810，介於 GitHub Model A（Adj. R^2 0.701）與 Model B（Adj. R^2 0.832）之間。以下為可能的原因，屬推論而非已證實的因果：

- **Model B 較高**：完整的 Zipcode One-Hot 讓模型能為特定高價社區（如 Medina、Mercer Island）加上各自的價差，擬合度因此較高。這是 NotebookLM 的推測，來源 README 並未直接這樣說明。
- **本研究高於 Model A**：同為 17 個特徵，本研究的指標較高。可能與 log 轉換及以經緯度、市中心距離表達地段有關，但因兩者評估方式不同，不能斷言是這些設計造成差距。

對方有、本研究沒有的技巧

- Zipcode 類別編碼或分級，可直接捕捉社區層級的價差。
- 以 Folium、Geopandas、GeoJSON 製作互動式空間地圖。
- 結合交易月份與季節的商業分析，提出行銷時間建議（例如 3 至 4 月）。

本研究有、對方 README 未提及的做法

- 目標變數與面積取 log，改善價格右偏。
- VIF 多重共線性檢驗，並處理 sqft_above 與 sqft_living 的完全共線。
- 逐步迴歸與 LassoCV 的交叉比對。
- 完整的迴歸假設檢驗與殘差診斷（Durbin-Watson、Breusch-Pagan、Shapiro-Wilk、Cook's Distance）。
- 95% 信賴區間與預測區間（測試集覆蓋率 95.2%）。
- CRISP-DM 流程與模型封裝（.joblib 與 predict_price() 函式）。

9.3 共通重點摘要

在 King County 房價預測的解法中，共通重點包含：

1. **核心驅動因子一致**：居住面積 (sqft_living)、建築與裝修品質 (grade) 及臨水岸 (waterfront) 為影響房價最顯著的實體特徵。
2. **地理位置影響深遠**：地段對價差具決定性作用，不論是採用 Zipcode 獨熱編碼、分級，或經緯度與市中心距離，均必須納入地理資訊以捕捉區域溢價。
3. **共線與特徵處理**：面積特徵間易存在重疊與共線，需透過結構調整或剔除以穩定模型。
4. **模型效益**：多元線性回歸透過交叉驗證均展現良好穩定性，可解釋 70% 至 83% 的房價變異，顯著優於單純回歸。

9.4 模型改進方向

1. **結合區域類別特徵或空間滯後變數**：連續經緯度與市中心距離表現不錯，但難以完全捕捉特定高價郵遞區號（如 98039）的突發溢價；可嘗試加入 Zipcode 特徵，或以近鄰房價 (k-NN) 作為空間特徵。
2. **加入交互作用項**：例如「居住面積 × 臨水岸」、「建築品質 × 市中心距離」，捕捉優質地段搭配高規格房屋的協同溢價。
3. **採用穩健標準誤 (HC3)**：Breusch-Pagan 檢定顯示存在異質變異，改用穩健標準誤可讓顯著性檢定更可靠。
4. **引入非線性模型作為基準**：以 Random Forest、XGBoost 或 LightGBM 評估非線性與空間邊界效應能帶來多少預測精度提升。

> 以上改進尚未實作，也沒有實際跑出新的 R^2；若要寫進作業，建議先實作其中一至兩項並附上結果。

9.5 小結

- 與 GitHub 專案相比，本研究的特色在於 log 轉換、VIF 共線性處理、多種特徵選擇方法交叉比對，以及完整的假設檢驗與預測區間。
- 對方的特色在於 Zipcode 類別編碼，Model B 的 Adj. R^2（0.832）高於本研究的 0.810，顯示類別化的地段資訊值得納入。
- 兩者的指標不能直接比較，若要下定論，應在同一資料切分與同一指標下重新比較。